



## Instituto Politécnico Nacional Escuela Superior de Cómputo

Materia: Tópicos Selectos de Algoritmos Bioinspirados  
Grupo: 7BM1

Profesor: Daniel Molina Pérez  
Periodo: 2025/02

### Practica 01

#### *Maximizar Contraste en Imágenes Médicas.*

Realizado por:  
Carrillo Barreiro José Emiliano  
Martinez Ayala Gerardo  
Robles Otero José Ángel  
Vásquez Morales Haniel Ulises

#### **Abstract:**

Medical image processing is key for diagnosis, where contrast enhancement is essential for the correct identification of structures. In this practice, a bio-inspired algorithm is implemented to optimize metrics such as standard deviation (STD) or entropy to improve visual quality without distorting the original information. Using techniques based on swarm intelligence and natural evolution, the method dynamically adjusts the contrast enhancement parameters. The results demonstrate better visual perception and greater discrimination of key anatomical structures, facilitating medical interpretation.

#### **Resumen:**

Las imágenes médicas suelen presentar bajo contraste, lo que dificulta su análisis y diagnóstico. Para abordar este problema, se propone un algoritmo bioinspirado que optimiza métricas como la desviación estándar y la entropía, permitiendo mejorar la calidad visual sin comprometer la información original. Este enfoque adaptativo maximiza el detalle de las estructuras relevantes, facilitando su interpretación y apoyando la toma de decisiones clínicas.

Fecha: 19 de marzo de 2025

# Índice general

<b>1</b>	<b>Introducción</b>	<b>1-1</b>
<b>2</b>	<b>Objetivos del Proyecto</b>	<b>2-1</b>
2.1	Optimización del contraste mediante un algoritmo genético y la transformada sigmoide . .	2-1
2.2	Comparación y análisis de resultados . . . . .	2-1
2.3	Visualización y análisis . . . . .	2-1
<b>3</b>	<b>Marco Teórico</b>	<b>3-1</b>
3.1	Antecedentes sobre el Mejoramiento de Contraste en Imágenes Médicas . . . . .	3-1
3.2	Fundamentos Teóricos . . . . .	3-2
3.3	Marco Teórico Propuesto . . . . .	3-3
3.4	Conexión con la Literatura Existente . . . . .	3-5
<b>4</b>	<b>Metodología</b>	<b>4-1</b>
4.1	Inicialización de la Población . . . . .	4-1
4.2	Evaluación de Fitness . . . . .	4-1
4.3	Selección por Torneo . . . . .	4-2
4.4	Cruzamiento con SBX . . . . .	4-2
4.5	Mutación Polinomial . . . . .	4-3
4.6	Elitismo y Ciclo Evolutivo . . . . .	4-3
<b>5</b>	<b>Resultados y Discusión</b>	<b>5-1</b>
5.1	Análisis de los Resultados . . . . .	5-2
5.1.1	Consistencia y Robustez . . . . .	5-2
5.1.2	Comparación Entre Funciones Objetivo . . . . .	5-2
5.1.3	Parámetros Óptimos y Sensibilidad . . . . .	5-2
5.1.4	Transformación Sigmoidal . . . . .	5-2
5.2	Discusión de Resultados . . . . .	5-3
5.2.1	Limitaciones de la Optimización con Entropía de Shannon . . . . .	5-3
5.2.2	Irreversibilidad de las Operaciones de Contraste y su Efecto en la Entropía . . . .	5-3
5.2.3	Lecciones Aprendidas . . . . .	5-4
5.2.4	Visualización de Resultados . . . . .	5-4
5.3	Pensamientos Finales . . . . .	5-7
<b>6</b>	<b>Implementación del Algoritmo Genético</b>	<b>6-1</b>
6.1	Fundamento Teórico . . . . .	6-1
6.1.1	Transformación Sigmoidal . . . . .	6-2
6.1.2	Función de Aptitud . . . . .	6-2
6.2	Estructura del Código Principal . . . . .	6-2
6.2.1	Definición de la Clase . . . . .	6-3
6.2.2	Inicialización de la Población . . . . .	6-3
6.2.3	Evaluación de la Aptitud . . . . .	6-4
6.3	Operadores Genéticos . . . . .	6-4
6.3.1	Cruce SBX . . . . .	6-4
6.3.2	Mutación Polinomial . . . . .	6-5
6.4	Ejecución del Algoritmo . . . . .	6-5
6.5	Utilidades de Procesamiento de Imágenes . . . . .	6-6
6.5.1	Transformación Sigmoidal . . . . .	6-6



6.5.2	Cálculo de Entropía . . . . .	6-6
6.5.3	Cálculo de Desviación Estándar . . . . .	6-7
<b>7</b>	<b>Conclusiones</b>	<b>7-1</b>
	<b>Bibliografía</b>	<b>7-1</b>
<b>A</b>	<b>GitHub</b>	<b>A-1</b>

# Índice de cuadros

3.1	Comparación de Técnicas de Mejoramiento de Contraste Tradicionales y Avanzadas . . .	3-2
3.2	Propiedades de las Funciones Sigmoidales Comunes . . . . .	3-5
3.3	Componentes Clave de un Algoritmo Genético . . . . .	3-5
5.1	Resumen Global de Corridas 01 - Imagen Médica 5R (Mano) . . . . .	5-1
5.2	Resumen Global de Corridas 02 - Imagen Médica 5R (Mano) . . . . .	5-1
5.3	Resumen Global de Corridas 01 - Imagen Médica 6R (Ojo) . . . . .	5-1
5.4	Resumen Global de Corridas 02 - Imagen Médica 6R (Ojo) . . . . .	5-1

# Índice de figuras

5.1	Comparación entre Imagen Médica 5R original y optimizada por entropía. . . . .	5-5
5.2	Comparación entre Imagen Médica 5R original y optimizada por desviación estándar. . .	5-5
5.3	Comparación entre Imagen Médica 6R original y optimizada por entropía. . . . .	5-6
5.4	Comparación entre Imagen Médica 6R original y optimizada por desviación estándar. . .	5-6

## Capítulo 1

# Introducción

El análisis de imágenes médicas desempeña un papel fundamental en el diagnóstico, la planificación del tratamiento y el seguimiento de diversas condiciones médicas. Dentro de este campo, el mejoramiento del contraste se erige como una etapa crucial para optimizar la calidad visual de las imágenes, facilitando la identificación de anomalías y la extracción de características relevantes. Las imágenes médicas a menudo presentan desafíos inherentes, como bajo contraste, ruido, pérdida de señal y estructuras anatómicas complejas, lo que puede dificultar un análisis y diagnóstico precisos. En este contexto, las exploraciones por tomografía computarizada (TC) con contraste mejorado se han consolidado como una herramienta esencial en el diagnóstico médico, permitiendo una representación más exacta de las estructuras internas del cuerpo y una detección superior de lesiones. La administración de agentes de contraste está específicamente diseñada para “iluminar” ciertas estructuras o áreas dentro del cuerpo humano, lo que conduce a una identificación más precisa de posibles problemas de salud.

La necesidad de técnicas efectivas de mejora del contraste en imágenes médicas es evidente debido a las dificultades que plantea el bajo contraste y la importancia de un diagnóstico certero. La investigación en esta área es, por lo tanto, de gran relevancia e impacto, ya que aborda un desafío fundamental que afecta directamente la capacidad de los profesionales médicos para realizar diagnósticos precisos.

En los últimos años, se ha observado una creciente aplicación de la inteligencia computacional, como los algoritmos genéticos, en el ámbito del mejoramiento de imágenes médicas. Si bien existen técnicas tradicionales de mejora del contraste, que incluyen la modificación del histograma y la corrección gamma, así como técnicas avanzadas como CLAHE (Ecuación de Histograma Adaptativa con Límite de Contraste), los algoritmos genéticos (AGs) ofrecen un enfoque alternativo para abordar la complejidad de este problema. Los AGs son técnicas de optimización metaheurísticas inspiradas en el proceso de selección natural, empleadas para encontrar soluciones óptimas a problemas complejos. Estos algoritmos resultan particularmente efectivos en problemas donde la función objetivo es discontinua, no diferenciable, estocástica o altamente no lineal, características que pueden presentarse en las tareas de procesamiento de imágenes. Los AGs operan sobre una población de soluciones candidatas que evolucionan a lo largo de generaciones mediante la aplicación de operadores de selección, cruce y mutación. La tendencia hacia el uso de la inteligencia computacional para la mejora de imágenes sugiere que los métodos tradicionales pueden tener limitaciones o que las técnicas más recientes ofrecen ventajas en escenarios específicos. Los algoritmos genéticos, con su capacidad para manejar problemas de optimización complejos, se presentan como una técnica avanzada viable.

El presente reporte se centra en el desarrollo de un marco teórico para un estudio que investiga el mejoramiento de contraste en imágenes médicas utilizando un algoritmo genético con transformación sigmoide. La investigación propuesta realiza una comparación entre la maximización de la entropía de la imagen y la maximización de la desviación estándar de la intensidad de los píxeles como funciones objetivo dentro del proceso de optimización. El estudio utilizará una función sigmoide para la transformación de la intensidad de la imagen, y el algoritmo genético optimizará los parámetros de esta transformación. El proceso de optimización estará guiado por dos funciones objetivo distintas: la maximización de la entropía de la imagen y la maximización de la desviación estándar de la intensidad de los píxeles. Este reporte proporcionará la base teórica para este enfoque y la comparación de estas dos funciones objetivo.

## Capítulo 2

# Objetivos del Proyecto

### 2.1 Optimización del contraste mediante un algoritmo genético y la transformada sigmoide

Desarrollar un Algoritmo Genético (AG) para optimizar el contraste de una imagen ajustando los parámetros  $\alpha$  y  $\Delta$  de la transformada sigmoide, mejorando así la calidad visual.

### 2.2 Comparación y análisis de resultados

Comparar los resultados obtenidos al optimizar la imagen utilizando entropía de Shannon y desviación estándar como métricas, analizando su efectividad y comportamiento en distintas imágenes.

### 2.3 Visualización y análisis

Mostrar la imagen con el mejor contraste obtenido según la métrica de evaluación seleccionada, permitiendo una comparación visual con la imagen original.

## Capítulo 3

# Marco Teórico

### 3.1 Antecedentes sobre el Mejoramiento de Contraste en Imágenes Médicas

El mejoramiento del contraste reviste una gran importancia en el ámbito de las imágenes médicas. Este proceso realza la claridad de las imágenes, permitiendo a los radiólogos evaluar las estructuras con mayor detalle. Al aumentar la sensibilidad de los exámenes, se proporciona información más detallada a los médicos. Es vital para la evaluación, el diagnóstico y el tratamiento de numerosas afecciones, tanto rutinarias como críticas, incluyendo accidentes cerebrovasculares, síndromes coronarios agudos y traumatismos. En el campo de la oncología, resulta crucial para evaluar las características de los tumores, su vascularización y posibles metástasis. En neurología, facilita el examen del sistema nervioso y los cambios degenerativos en el cerebro. Además, mejora la diferenciación entre tejidos blandos como músculos, tendones y órganos internos. La trascendencia clínica del mejoramiento del contraste se manifiesta en su amplia aplicación a través de diversas especialidades y condiciones médicas. Esta extensa aplicabilidad subraya la relevancia práctica y el potencial impacto de la investigación en esta área.

A lo largo del tiempo, se han desarrollado diversas técnicas para mejorar el contraste en imágenes médicas, las cuales pueden clasificarse en tradicionales y avanzadas. Entre las técnicas tradicionales, se encuentran la transformación del nivel de gris y la transformación del histograma, métodos comúnmente utilizados. La ecualización del histograma (HE) es una técnica popular que mapea los niveles de gris basándose en la distribución de probabilidad para lograr un histograma más uniforme y, por ende, mejorar el contraste. La corrección gamma ajusta el brillo de la imagen mediante un parámetro gamma. El mejoramiento de contraste morfológico emplea transformaciones de sombrero de copa blanco y negro. También existen métodos basados en wavelets, descomposición modal empírica bidimensional, estiramiento de la descorrelación, basados en ecuaciones diferenciales parciales y basados en filtros de mediana.

En cuanto a las técnicas avanzadas, la ecualización de histograma adaptativa (AHE) proporciona una mejora del contraste local al calcular histogramas de ventanas locales. La ecualización de histograma adaptativa con límite de contraste (CLAHE) es una generalización de AHE que limita la cantidad de mejora del contraste local para reducir la amplificación del ruido. Adicionalmente, se están explorando técnicas que involucran autoencoders profundos y métodos de mejora de imágenes con poca luz.

A pesar de la existencia de numerosas técnicas de mejora del contraste, a menudo presentan limitaciones y compromisos. Por ejemplo, la ecualización del histograma puede degradar la calidad de la imagen si la imagen original no tiene bajo contraste. Los métodos tradicionales a veces pueden generar amplificación de ruido o sobre-saturación. La corrección gamma requiere una selección cuidadosa del valor gamma, lo cual puede ser un desafío. Estas limitaciones motivan la exploración de métodos alternativos, como aquellos basados en algoritmos genéticos y funciones sigmoidales, que podrían ofrecer ventajas en contextos específicos.

Cuadro 3.1: Comparación de Técnicas de Mejoramiento de Contraste Tradicionales y Avanzadas

Técnica	Nombre	Principio Básico	Ventajas	Limitaciones	Ejemplo de Aplicación
Ecualización del Histograma (HE)		Mapeo de niveles de gris basado en la distribución de probabilidad.	Simple, explícita, mejora el contraste en imágenes de bajo contraste.	Puede degradar la calidad en imágenes con buen contraste inicial.	Procesamiento de imágenes médicas, radar.
Corrección Gamma		Ajuste del brillo de la imagen mediante un parámetro gamma.	Preserva el brillo, mejora el rango dinámico.	La selección óptima del valor gamma es crucial y puede ser dependiente del contenido de la imagen.	Amplia aplicación en imágenes médicas.
Ecualización Adaptativa del Histograma (AHE)		Cálculo del histograma en ventanas locales para la mejora del contraste.	Mejora el contraste local, realza detalles en diferentes regiones de la imagen.	Puede amplificar el ruido en áreas homogéneas.	
CLAHE		Similar a AHE pero limita la mejora del contraste local para reducir el ruido.	Reduce la amplificación del ruido, previene la sobresaturación, mejora el contraste local.		Imágenes médicas de bajo contraste, como películas de portal.

## 3.2 Fundamentos Teóricos

La función sigmoide desempeña un papel crucial en el ajuste del contraste de las imágenes. Una función sigmoide es una función matemática con forma de “S”, acotada y diferenciable. Ejemplos comunes incluyen la función logística ( $\sigma(x) = 1/(1 + e^{-x})$ ) y la función tangente hiperbólica. La salida de una función sigmoide logística estándar se encuentra en el rango de 0 a 1, lo que la hace adecuada para mapear las intensidades de los píxeles a un rango normalizado. Las funciones sigmoideas son monótonas y poseen una primera derivada con forma de campana. Además, introducen no linealidad, una propiedad esencial para aprender relaciones complejas en los datos.

En el procesamiento de imágenes, las funciones sigmoideas pueden utilizarse para ajustar los valores de intensidad de los píxeles, realzando el contraste entre las regiones oscuras y claras. Al variar los parámetros de la función sigmoide (por ejemplo, la pendiente y el centro), es posible controlar el contraste de una imagen. Se han empleado funciones sigmoideas adaptativas para la mejora del contraste de imágenes, a veces en combinación con la ecualización bihistograma. También se han propuesto operadores de función sigmoide cuartílica para compensar la pérdida perceptual en el contraste de luminosidad al escalar imágenes a dispositivos con un rango dinámico limitado. Las propiedades de la función sigmoide, en particular su salida acotada y su naturaleza no lineal, la convierten en una herramienta adecuada para la manipulación del contraste de imágenes. La capacidad de ajustar sus parámetros proporciona una forma flexible de controlar el grado de mejora.

Los algoritmos genéticos proporcionan un marco robusto para optimizar los parámetros de la función sigmoide para el mejoramiento del contraste de imágenes. Los AGs se inspiran en la selección natural y la genética, imitando el proceso evolutivo para encontrar soluciones óptimas. Operan sobre una población de soluciones candidatas (cromosomas), donde cada cromosoma representa una posible solución al problema de optimización. El algoritmo evoluciona iterativamente esta población a lo largo de generaciones para mejorar la aptitud de las soluciones.

Los componentes clave de un algoritmo genético incluyen:

- **Población:** Un conjunto de soluciones candidatas (individuos o cromosomas).
- **Función de Aptitud:** Evalúa la calidad de cada solución, guiando el proceso de selección. En este contexto, las funciones objetivo (entropía y desviación estándar) servirán como funciones de aptitud.



- **Selección:** Elige individuos con mayor aptitud para convertirse en padres para la siguiente generación. Los métodos comunes incluyen la ruleta, el torneo y la selección basada en el rango.
- **Cruce (Recombinación):** Combina el material genético de dos padres para crear nuevos descendientes. Las técnicas comunes incluyen el cruce de un punto, multipunto y uniforme.
- **Mutación:** Introduce cambios aleatorios en los cromosomas de los descendientes para mantener la diversidad y explorar nuevas partes del espacio de búsqueda.

Los AGs son adecuados para el procesamiento de imágenes ya que pueden manejar funciones objetivo complejas y no lineales que podrían ser difíciles para los métodos de optimización tradicionales. Son menos sensibles al punto de partida en comparación con los métodos basados en gradiente. Los AGs pueden explorar un gran espacio de soluciones para encontrar parámetros casi óptimos para la mejora de imágenes. La capacidad de los AGs para manejar espacios de búsqueda complejos y relaciones no lineales los hace idóneos para esta tarea.

Las funciones objetivo son métricas que guían el proceso de optimización en un algoritmo genético. En el contexto del mejoramiento del contraste de imágenes, tanto la maximización de la entropía como la maximización de la desviación estándar son enfoques comunes.

La maximización de la entropía se basa en el concepto de la teoría de la información, donde la entropía mide la aleatoriedad o la incertidumbre en un sistema. En una imagen, refleja la distribución de las intensidades de los píxeles. Una imagen con mayor entropía típicamente presenta una distribución más amplia y uniforme de las intensidades de los píxeles, lo que a menudo se asocia con un mayor contraste y una mejor visibilidad de los detalles. Maximizar la entropía como función objetivo busca dispersar el histograma de intensidad de los píxeles, mejorando así el contraste general de la imagen.

La maximización de la desviación estándar utiliza una medida estadística de la dispersión de un conjunto de valores. En una imagen, refleja la dispersión de los valores de intensidad de los píxeles alrededor de la intensidad media. Una desviación estándar más alta indica una mayor diferencia entre las áreas oscuras y claras de la imagen, lo que corresponde a un mayor contraste. Maximizar la desviación estándar como función objetivo busca aumentar la diferencia entre los valores extremos de intensidad de los píxeles, realzando de esta manera el contraste de la imagen.

La elección de la entropía y la desviación estándar como funciones objetivo proporciona dos perspectivas distintas sobre lo que constituye un buen contraste. La entropía se centra en la distribución general de las intensidades de los píxeles, mientras que la desviación estándar enfatiza la dispersión de los valores. La comparación de estas dos funciones objetivo proporcionará información sobre cuál de las dos es más eficaz para guiar al algoritmo genético hacia la consecución de un mejor mejoramiento del contraste en imágenes médicas. Comparar su efectividad dentro del marco del AG ofrecerá información valiosa sobre la relación entre la distribución de píxeles y el contraste percibido en imágenes médicas.

### 3.3 Marco Teórico Propuesto

El marco teórico propuesto se basa en un modelo conceptual que ilustra el proceso de mejoramiento del contraste de imágenes médicas utilizando un algoritmo genético con transformación sigmoide y la comparación de dos funciones objetivo. El proceso se puede describir de la siguiente manera:

1. Se toma una imagen médica de entrada.
2. Se inicializa una población de conjuntos de parámetros de la función sigmoide (cromosomas).
3. Para cada generación:
  - a) Se aplica cada conjunto de parámetros a la imagen de entrada para generar imágenes mejoradas.
  - b) Se calcula la aptitud de cada imagen mejorada utilizando ambas funciones objetivo (entropía y desviación estándar).
  - c) Se seleccionan conjuntos de parámetros padres en función de su aptitud para cada función objetivo.

- d) Se realizan operaciones de cruce y mutación en los padres seleccionados para crear una nueva generación de conjuntos de parámetros.
4. Se repiten los pasos hasta que se cumple un criterio de parada (por ejemplo, un número máximo de generaciones, una aptitud satisfactoria).
5. Se obtienen las imágenes mejoradas y los parámetros óptimos correspondientes de la función sigmoide para ambas funciones objetivo.

Se proponen las siguientes hipótesis para guiar la investigación:

- **Hipótesis 1:** El algoritmo genético que utiliza la maximización de la entropía como función objetivo resultará en imágenes médicas con una distribución más uniforme de las intensidades de los píxeles y un mayor detalle general.
- **Hipótesis 2:** El algoritmo genético que utiliza la maximización de la desviación estándar como función objetivo conducirá a imágenes médicas con una mayor diferencia entre las regiones oscuras y claras, lo que resultará en un mejor contraste local.
- **Hipótesis 3:** La efectividad de la maximización de la entropía y la maximización de la desviación estándar en la mejora del contraste variará dependiendo del tipo específico y las características de las imágenes médicas que se estén procesando.

Las variables clave y sus relaciones anticipadas en este estudio son:

#### **Variables Independientes:**

- Parámetros de la función sigmoide (por ejemplo, centro, pendiente).
- Parámetros del algoritmo genético (por ejemplo, tamaño de la población, tasa de cruce, tasa de mutación, número de generaciones).
- Elección de la función objetivo (maximización de la entropía vs. maximización de la desviación estándar).
- Tipo y características de las imágenes médicas de entrada.

#### **Variables Dependientes:**

- Medidas cuantitativas del contraste de la imagen (por ejemplo, entropía, desviación estándar, relación contraste-ruido, índice de similitud estructural).
- Evaluación cualitativa del contraste de la imagen y la calidad diagnóstica por parte de expertos médicos.

#### **Relaciones Anticipadas:**

- Configuraciones específicas de los parámetros de la función sigmoide tendrán un impacto directo en el contraste de la imagen resultante.
- Los parámetros del algoritmo genético influirán en la eficiencia y efectividad del proceso de optimización.
- La elección de la función objetivo determinará las características específicas de la mejora del contraste lograda.
- Diferentes tipos de imágenes médicas podrían responder de manera diferente a las dos estrategias de optimización.

Este marco teórico se basa en las siguientes suposiciones subyacentes:

- La maximización de la entropía y la desviación estándar son indicadores relevantes de una mejora del contraste visual en imágenes médicas.
- La parametrización elegida de la función sigmoide es lo suficientemente flexible como para lograr una mejora del contraste eficaz para las imágenes médicas objetivo.
- Los parámetros del algoritmo genético pueden ajustarse para garantizar la convergencia a una solución casi óptima dentro de un plazo razonable.

- Las evaluaciones cualitativas realizadas por expertos médicos pueden proporcionar una medida fiable de la utilidad clínica de las imágenes mejoradas.

Cuadro 3.2: Propiedades de las Funciones Sigmoidales Comunes

Función Sigmoidal de Nombre	Fórmula	Rango de Salida	Propiedades Clave
Función Logística	$\sigma(x) = 1/(1 + e^{-x})$	(0, 1)	Monotónicamente creciente, diferenciable, salida entre 0 y 1.
Tangente Hipérbolica (tanh)	$\tanh(x) = (e^x - e^{-x})/(e^x + e^{-x})$	(-1, 1)	Monotónicamente creciente, diferenciable, simétrica alrededor del origen, salida entre -1 y 1.

Cuadro 3.3: Componentes Clave de un Algoritmo Genético

Componente Nombre	Descripción	Rol en el Algoritmo
Población	Conjunto de soluciones candidatas (cromosomas).	Representa el espacio de búsqueda y evoluciona hacia la solución óptima.
Función de Aptitud	Evalúa la calidad de cada cromosoma.	Guía el proceso de selección favoreciendo soluciones de alta calidad.
Selección	Proceso de elegir cromosomas para la reproducción.	Asegura que los genes de los individuos más aptos se transmitan a la siguiente generación.
Cruce	Combinación del material genético de dos padres.	Crea nuevos descendientes con características de ambos padres, explorando nuevas soluciones.
Mutación	Introducción de cambios aleatorios en los cromosomas.	Mantiene la diversidad genética y evita la convergencia prematura a óptimos locales.

## 3.4 Conexión con la Literatura Existente

Es fundamental revisar la literatura existente sobre el uso de funciones sigmoidales para el mejoramiento del contraste de imágenes. Diversos estudios han explorado la aplicación de funciones sigmoidales en este campo, demostrando su capacidad para ajustar las intensidades de los píxeles y mejorar la calidad visual de las imágenes. Además, es importante investigar la investigación sobre la aplicación de algoritmos genéticos en el procesamiento y la optimización de imágenes médicas. Los AGs se han utilizado con éxito en una variedad de tareas de procesamiento de imágenes, incluyendo la segmentación, la selección de características y la mejora de la calidad de la imagen.

También se debe investigar estudios que hayan utilizado la entropía y la desviación estándar como funciones objetivo para la mejora de imágenes o en otras tareas de procesamiento de imágenes. La entropía y la desviación estándar son métricas comunes utilizadas para evaluar el contraste y la calidad de las imágenes, y su uso como funciones objetivo en algoritmos de optimización puede conducir a resultados significativos.

El marco teórico propuesto se basa en el conocimiento existente y potencialmente lo extiende. Es crucial identificar si existen estudios que comparen directamente estas dos funciones objetivo dentro de un marco de transformación sigmoide basado en AGs para imágenes médicas. Al resaltar cómo este trabajo se relaciona con la literatura existente y al identificar cualquier laguna que esta investigación pretende abordar, se puede establecer la novedad y la contribución de este estudio.

## Capítulo 4

# Metodología

### 4.1 Inicialización de la Población

La población inicial se genera de forma uniforme a lo largo del espacio de búsqueda, definido por límites inferiores y superiores para cada variable.

#### Objetivo

Garantizar que la búsqueda comience explorando de manera equitativa todas las regiones posibles, evitando sesgos que puedan limitar la diversidad de soluciones iniciales.

#### Implementación

Se utiliza la función `initialize_population`, la cual emplea métodos de generación aleatoria (por ejemplo, la función `np.random.uniform` de NumPy) para crear un conjunto de individuos.

#### Ventajas

- Permite cubrir todo el rango definido para cada variable.
- Aumenta la probabilidad de encontrar regiones prometedoras del espacio de soluciones desde el inicio.

### 4.2 Evaluación de Fitness

Cada individuo generado se evalúa mediante la función objetivo, la cual determina qué tan buena es la solución propuesta.

#### Funciones Utilizadas

- **Entropía de Shannon:** Se utiliza para medir la cantidad de información contenida en la imagen transformada. Un mayor valor de entropía indica una distribución de intensidades más uniforme y, por lo tanto, un mejor contraste.

- **Desviación estandar:** Evalúa la dispersión de los niveles de intensidad en la imagen. Una mayor desviación estándar sugiere una mayor separación entre tonos oscuros y claros, lo que contribuye a un mayor contraste.

## Proceso

Para cada individuo en la población, se aplican los valores de  $\alpha$  y  $\Delta$  ( $x_1, x_2$ ) a la transformada sigmoide, obteniendo una imagen modificada. Posteriormente se calculan las métricas de Desviación estandar y entropía y se almacena dicho valor para posteriores comparaciones.

## Importancia

La evaluación correcta del fitness es crucial, ya que determina la selección de individuos y, por ende, el rumbo de la evolución poblacional.

## 4.3 Selección por Torneo

Para elegir los padres que generarán la siguiente generación se utiliza un método de selección por torneo.

### Mecanismo

- Se forman múltiples grupos (torneos) de individuos seleccionados al azar.
- En cada grupo se compara el fitness de los participantes y se selecciona al individuo con el mejor desempeño.

### Implementación Vectorizada

La función `vectorized_tournament_selection` realiza este proceso de forma eficiente, aprovechando operaciones vectorizadas de NumPy.

### Beneficios

- Favorece la selección de soluciones de alta calidad sin descartar por completo la diversidad poblacional.
- Permite controlar la presión selectiva mediante el tamaño del torneo.

## 4.4 Cruzamiento con SBX

El operador de cruzamiento se implementa mediante el método SBX (Simulated Binary Crossover).

### Proceso del SBX

- A partir de dos padres, se genera un número aleatorio  $u$  y se calcula un parámetro  $\beta$  que determina la dispersión de los descendientes respecto a los padres.
- Se generan dos hijos combinando linealmente los valores de los padres.

## Ajuste de Límites

Se incorpora un mecanismo en `sbx_crossover_with_boundaries` que garantiza que los hijos resultantes se mantengan dentro de los límites predefinidos.

## Ventajas

- Promueve la creación de soluciones intermedias que pueden explotar la información genética de ambos padres.
- Ayuda a preservar la diversidad en la población.

## 4.5 Mutación Polinomial

Para introducir variabilidad y explorar nuevas regiones del espacio de búsqueda, se aplica la mutación polinomial.

### Mecanismo de la Mutación

- Cada gen de un individuo tiene una probabilidad definida de sufrir una mutación.
- Se usa una distribución polinomial, controlada por el parámetro  $\eta_{mut}$ .

### Consideraciones de Límites

La mutación se aplica respetando los límites definidos para cada variable mediante la función `polynomial_mutation_with_L`.

### Beneficios

- Introduce pequeñas variaciones que pueden conducir a la exploración de nuevas soluciones.
- Previene la convergencia prematura al mantener la diversidad genética.

## 4.6 Elitismo y Ciclo Evolutivo

El proceso evolutivo se estructura en ciclos o generaciones.

### Elitismo

- Se retiene el mejor individuo de la generación actual y se garantiza su inclusión en la siguiente generación.
- Esto asegura que la calidad de la solución nunca empeore a lo largo de las generaciones.

### Ciclo Evolutivo

- Cada generación incluye la selección, el cruzamiento, la mutación y la incorporación del individuo de élite.
- La evolución se repite durante un número predefinido de generaciones.

## Registro y Análisis

- Se almacena el historial del fitness y de las mejores soluciones.
- Esto facilita el análisis del comportamiento del algoritmo y la generación de visualizaciones.

## Capítulo 5

# Resultados y Discusión

Durante la ejecución del algoritmo genético para la mejora de contraste en imágenes médicas, se realizaron múltiples corridas completas para cada función objetivo (maximización de entropía y maximización de desviación estándar), lo que permitió evaluar la estabilidad y eficiencia del método. Los resultados se consolidaron en resúmenes globales, registrando indicadores clave que se presentan en las siguientes tablas:

Cuadro 5.1: Resumen Global de Corridas 01 - Imagen Médica 5R (Mano)

Indicador	Optimización de Entropía	Optimización de Desviación Estándar
Mejor (Fitness)	-4.128421621722379	-0.1953755630183538
Peor (Fitness)	-4.128421621722379	-0.195375555673538
Media	-4.128421621722379	-0.1953755630183538
Desv. Estándar	0.0	7.51e-09

Cuadro 5.2: Resumen Global de Corridas 02 - Imagen Médica 5R (Mano)

Indicador	Optimización de Desviación Estándar
Mejor (Fitness)	120.061897
Peor (Fitness)	120.245979
Media	120.14108900000001
Desv. Estándar	0.07353604532132446

Cuadro 5.3: Resumen Global de Corridas 01 - Imagen Médica 6R (Ojo)

Indicador	Optimización de Entropía	Optimización de Desviación Estándar
Mejor (Fitness)	-6.84574278505749	-0.2244060136302129
Peor (Fitness)	-6.84574278505749	-0.2244058045302129
Media	-6.84574278505749	-0.2244060136302129
Desv. Estándar	0.0	1.91e-05

Cuadro 5.4: Resumen Global de Corridas 02 - Imagen Médica 6R (Ojo)

Indicador	Optimización de Entropía	Optimización de Desviación Estándar
Mejor (Fitness)	4.7195	122.711517
Peor (Fitness)	4.7211	122.773857
Media	4.72044	122.7600892
Desv. Estándar	0.0006066300355240354	0.027192434392680088

Los indicadores representan lo siguiente:



- **Mejor (Fitness):** Valor mínimo de fitness obtenido en todas las corridas, indicando la mejor solución encontrada.
- **Peor (Fitness):** Valor máximo de fitness entre las soluciones óptimas, reflejando la variabilidad máxima.
- **Media:** Promedio de los valores de fitness de las mejores soluciones por corrida, proporcionando una medida global del desempeño.
- **Desv. Estándar:** Dispersión de los valores de fitness entre corridas, indicando la estabilidad del algoritmo.

## 5.1 Análisis de los Resultados

### 5.1.1. Consistencia y Robustez

Los resúmenes globales muestran que el algoritmo genético converge consistentemente hacia soluciones de alta calidad. La desviación estándar extremadamente baja en la optimización de entropía (0.0 para ambas imágenes) indica una robustez notable, sugiriendo que el proceso evolutivo es reproducible y poco afectado por la aleatoriedad de los operadores genéticos.

### 5.1.2. Comparación Entre Funciones Objetivo

#### Optimización de Entropía

La optimización de entropía logra soluciones consistentes con desviación estándar nula en las corridas 01 para ambas imágenes. Para la Imagen 5R, los valores óptimos fueron  $\alpha = 8,2005$  y  $\delta \approx 0$ , mientras que para la Imagen 6R fueron  $\alpha \approx 0$  y  $\delta \approx 0$ , mostrando una alta sensibilidad a las características de cada imagen.

#### Optimización de Desviación Estándar

La optimización de desviación estándar converge a valores bajos de fitness con ligera variación. Para ambas imágenes,  $\alpha$  tiende al límite superior (aproximadamente 10), con  $\delta \approx 0$  para la Imagen 5R y  $\delta \approx 0,41$  para la Imagen 6R, indicando una preferencia por transformaciones de pendiente pronunciada.

### 5.1.3. Parámetros Óptimos y Sensibilidad

- **Parámetro Alpha:** Controla la pendiente de la transformación sigmoideal. La optimización de desviación estándar lo empuja hacia valores altos, mientras que la de entropía varía según la imagen.
- **Parámetro Delta:** Ajusta el desplazamiento del punto medio. Muestra mayor variabilidad y especificidad según la imagen y la métrica utilizada.

### 5.1.4. Transformación Sigmoideal

La mejora del contraste se basa en la función sigmoideal:

$$\text{sigmoid}(x) = \frac{1}{1 + \exp(-\alpha \cdot (x - \delta))} \quad (5.1)$$

donde  $\alpha$  afecta la intensidad del contraste y  $\delta$  el brillo.

## 5.2 Discusión de Resultados

- **Eficacia del Algoritmo:** Los indicadores globales confirman la capacidad del algoritmo para optimizar el contraste, con alta consistencia en la optimización de entropía.
- **Especificidad de la Imagen:** Las diferencias en parámetros óptimos entre las imágenes 5R y 6R subrayan la necesidad de enfoques adaptativos.
- **Selección de Métricas:** La optimización de entropía preserva información, mientras que la de desviación estándar maximiza contraste visual.
- **Equilibrio Exploración-Explotación:** Los operadores (selección por torneo, cruce SBX, mutación polinomial) con 100 individuos y 50 generaciones logran un balance efectivo.
- **Aplicaciones Clínicas:** La robustez sugiere viabilidad para entornos clínicos donde la reproducibilidad es esencial.

### 5.2.1. Limitaciones de la Optimización con Entropía de Shannon

Los resultados con la optimización de entropía muestran una consistencia notable, pero no siempre producen mejoras visuales óptimas, especialmente en la Imagen 6R ( $\alpha \approx 0$ ,  $\delta \approx 0$ ). Esto puede explicarse por las limitaciones teóricas de la entropía como métrica. Según Gonzalez y Woods (página 547):

“Recordemos que el código de longitud variable en el Ejemplo 8.1 pudo representar las intensidades de la imagen en la Fig. 8.1(a) usando solo 1.81 bits/píxel. Aunque esto es mayor que la estimación de entropía de 1.6614 bits/píxel del Ejemplo 8.2, el primer teorema de Shannon, también llamado teorema de codificación sin ruido (Shannon [1948]), nos asegura que la imagen en la Fig. 8.1(a) puede representarse con tan solo 1.6614 bits/píxel. Para probarlo de manera general, Shannon consideró representar grupos de símbolos fuente consecutivos con una sola palabra de código (en lugar de una palabra por símbolo), y demostró que  $\lim_{n \rightarrow \infty} \left\lceil \frac{L_{avg,n}}{n} \right\rceil = H$ , donde  $L_{avg,n}$  es el número promedio de símbolos de código necesarios para representar todos los grupos de  $n$  símbolos.”

La entropía de Shannon mide la información teórica en una fuente sin memoria, asumiendo píxeles independientes. Sin embargo, en imágenes médicas reales, los píxeles están correlacionados espacialmente, lo que reduce la efectividad de la entropía como métrica directa de contraste visual. Esta correlación implica que la maximización de la entropía puede no reflejar mejoras perceptuales, ya que se enfoca en la uniformidad de la distribución de intensidades más que en la visibilidad de estructuras específicas.

### 5.2.2. Irreversibilidad de las Operaciones de Contraste y su Efecto en la Entropía

Las operaciones de contraste aplicadas no son reversibles, lo que tiene implicaciones directas en la entropía de la imagen transformada. Esto se debe a dos razones principales:

1. **Profundidad de bits finita:** La imagen tiene una profundidad de bits limitada, lo que provoca redondeo y mapeo de diferentes valores de intensidad originales en  $X$  a un mismo valor en la imagen transformada  $Y$ .
2. **Recorte en valores extremos:** Los valores de intensidad pueden saturarse al alcanzar los límites del rango, lo que también contribuye a la pérdida de información.

Como resultado, la entropía condicional  $H(X|Y) > 0$ , donde  $X$  es la imagen original y  $Y$  la imagen transformada, indicando que no es posible recuperar completamente  $X$  a partir de  $Y$ . Dado que la transformación es determinista (es decir,  $Y = F(X)$ ), la entropía condicional  $H(Y|X) = 0$ , lo que implica:

$$H(Y) = I(X; Y) + H(Y|X) = I(X; Y) + 0 = I(X; Y) < H(X)$$

Por lo tanto, cualquier operación de contraste que no sea reversible reducirá la entropía en comparación con la imagen original. Esto explica por qué, en algunos casos, la optimización basada en entropía puede no conducir a mejoras visuales perceptibles, ya que la maximización de  $H(Y)$  no necesariamente corresponde a un aumento en el contraste visual debido a la pérdida de información inherente.

**Detalles adicionales sobre la irreversibilidad:** Las operaciones de contraste no son revertibles simplemente porque:

- **\*\*La profundidad de bits finita de la imagen\*\*** implica que ocurre cierto redondeo, y diferentes valores en  $X$  se mapean al mismo valor en  $Y$ . - **\*\*El recorte en los valores extremos\*\*** ocurre cuando se alcanzan los límites del rango de intensidad, lo que también reduce la información disponible.

Esto significa que  $H(X|Y) > 0$ , y dado que  $I(X;Y) < H(X)$ , pero  $H(Y|X) = 0$  por la naturaleza determinista de la operación, se confirma que:

$$H(Y) = I(X;Y) < H(X)$$

Lo que observamos es exactamente esto: todas las operaciones de estiramiento o reducción de contraste disminuyen la entropía en comparación con la imagen original.

### 5.2.3. Lecciones Aprendidas

A partir de este análisis, podemos extraer las siguientes conclusiones clave sobre la relación entre contraste y entropía:

- **Alto contraste es una condición necesaria, pero no suficiente, para una alta entropía:** Aunque el contraste puede mejorar la percepción visual, no garantiza una mayor entropía si se pierde información en el proceso.
- **La entropía está limitada por el número de valores ocupados:** Si la transformación reduce la cantidad de niveles de intensidad distintos, la entropía disminuye.
- **La entropía es invariante a operaciones reversibles (y deterministas):** Solo las transformaciones que preservan toda la información original mantienen la entropía intacta.
- **La entropía se reduce por operaciones deterministas no reversibles:** Como se demostró, las operaciones de contraste aplicadas aquí siempre disminuyen  $H(Y)$  respecto a  $H(X)$ .

Estas lecciones subrayan la importancia de elegir métricas adecuadas según el objetivo: maximizar la entropía no siempre equivale a mejorar el contraste visual, especialmente en imágenes con limitaciones prácticas como profundidad de bits finita.

### 5.2.4. Visualización de Resultados

Se generaron representaciones visuales para evaluar cualitativamente los efectos de la optimización:




Figura 5.1: Comparación entre Imagen Médica 5R original y optimizada por entropía.




Figura 5.2: Comparación entre Imagen Médica 5R original y optimizada por desviación estándar.




Figura 5.3: Comparación entre Imagen Médica 6R original y optimizada por entropía.



Figura 5.4: Comparación entre Imagen Médica 6R original y optimizada por desviación estándar.

## 5.3 Pensamientos Finales

El algoritmo genético implementado ha demostrado ser eficaz para la optimización de parámetros de transformación sigmoideal en la mejora de contraste de imágenes médicas. Los resultados indican que:

- La optimización de entropía y la de desviación estándar representan enfoques distintos: la primera preserva contenido informativo, mientras que la segunda maximiza el contraste visual.
- Las diferencias en parámetros óptimos entre imágenes resaltan la necesidad de técnicas adaptativas.
- La consistencia en las corridas sugiere fiabilidad para encontrar soluciones óptimas.
- Un sistema ideal podría combinar múltiples métricas para equilibrar preservación de información y mejora de contraste.

Estos resultados podrían sugerir que los algoritmos genéticos ofrecen un enfoque robusto y adaptable para mejorar la calidad de imágenes médicas, con potencial para aplicaciones clínicas que requieren precisión diagnóstica.

## Capítulo 6

# Implementación del Algoritmo Genético

En este capítulo se detalla la implementación del algoritmo genético (GA) diseñado para optimizar el contraste de imágenes médicas, utilizando C++ y la biblioteca OpenCV. El GA ajusta los parámetros  $\alpha$  y  $\delta$  de una transformación sigmoideal, maximizando métricas como la entropía de Shannon o la desviación estándar. Se describen los fundamentos teóricos, la estructura del código principal y los operadores de cruce y mutación utilizados.

## 6.1 Fundamento Teórico

Un algoritmo genético es una técnica de optimización inspirada en los principios de la evolución biológica, como la selección natural, la reproducción y la mutación. Este método pertenece a la familia de los algoritmos evolutivos y se utiliza para resolver problemas complejos de optimización donde los métodos tradicionales pueden ser insuficientes, como en la mejora del contraste de imágenes médicas.

El GA opera sobre una población de posibles soluciones, denominadas individuos. Cada individuo representa una combinación de parámetros que se desea optimizar. En este caso, los parámetros son  $\alpha$  y  $\delta$ , que controlan una transformación sigmoideal aplicada a las intensidades de los píxeles de una imagen. El objetivo es encontrar los valores óptimos de estos parámetros que maximicen una métrica específica de calidad de la imagen, como la entropía de Shannon o la desviación estándar.

El proceso evolutivo se desarrolla en iteraciones conocidas como generaciones, y en cada una de ellas se aplican los siguientes pasos:

- **Inicialización:** Se genera una población inicial de individuos con valores aleatorios dentro de rangos predefinidos (por ejemplo,  $\alpha \in [0, 20]$  y  $\delta \in [0, 1]$ ).
- **Evaluación de la aptitud:** Se calcula una función de aptitud para cada individuo, que mide qué tan buena es la solución que representa. En este caso, la aptitud puede ser la entropía o la desviación estándar de la imagen transformada.
- **Selección:** Se eligen los individuos más aptos (con mayor valor de aptitud) para que actúen como "padres" de la siguiente generación.
- **Cruce:** Se combinan pares de individuos seleccionados para producir "descendientes", intercambiando información genética (valores de  $\alpha$  y  $\delta$ ).
- **Mutación:** Se introducen pequeñas variaciones aleatorias en algunos individuos para mantener la diversidad en la población y evitar converger prematuramente a una solución subóptima.
- **Reemplazo:** La nueva población reemplaza a la anterior, preservando a veces al mejor individuo (elitismo), y el ciclo se repite hasta alcanzar un número fijo de generaciones o un criterio de parada.



### 6.1.1. Transformación Sigmoidal

El núcleo del problema radica en ajustar los parámetros de una transformación sigmoidal que mejora el contraste de la imagen. La ecuación de esta transformación es:

$$I'(x, y) = \frac{1}{1 + e^{-\alpha(I(x, y) - \delta)}} \quad (6.1)$$

donde:

- $I(x, y)$  es la intensidad original del píxel en la posición  $(x, y)$  de la imagen en escala de grises (normalizada entre 0 y 1).
- $I'(x, y)$  es la intensidad transformada del píxel.
- $\alpha$  controla la pendiente de la curva sigmoidal, determinando la brusquedad del cambio de intensidad.
- $\delta$  define el punto de inflexión de la curva, desplazando el rango de intensidades afectado.

Esta función transforma las intensidades de la imagen de manera no lineal, amplificando el contraste al mapear los valores originales a un rango que resalta diferencias entre regiones claras y oscuras.

### 6.1.2. Función de Aptitud

La función de aptitud es el criterio que guía la optimización. En este caso, se utilizan dos métricas comunes para evaluar el contraste de la imagen transformada:

**Entropía de Shannon:**

$$H = - \sum_{i=0}^{255} p_i \log_2(p_i) \quad (6.2)$$

donde  $p_i$  es la probabilidad de la intensidad  $i$ . Una mayor entropía indica una distribución más uniforme de intensidades, lo que suele corresponder a un mejor contraste.

**Desviación Estándar:**

$$\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2} \quad (6.3)$$

donde  $x_i$  son las intensidades de los píxeles,  $\mu$  es la media y  $N$  es el número total de píxeles. Una desviación estándar más alta implica mayor variabilidad en las intensidades, lo que también se asocia con un contraste mejorado.

El GA busca maximizar estas métricas, aunque en la implementación se minimiza el valor negativo de la entropía o la desviación estándar para adaptarse a la convención de minimización en muchos algoritmos.

## 6.2 Estructura del Código Principal

El núcleo del algoritmo está implementado en dos archivos: `genetic_algo_img.h` y `genetic_algo_img.cpp`. El primero define la clase `GeneticAlgorithmReal`, mientras que el segundo contiene la lógica de sus métodos.



### 6.2.1. Definición de la Clase

En `genetic_algo_img.h`, se declara la clase con los elementos esenciales para el GA:

```
1 class GeneticAlgorithmReal {
2 public:
3     enum class FitnessMetric { ENTROPY, STDDEV };
4 private:
5     int population_size;
6     int num_generations;
7     std::vector<double> lower_bound;
8     std::vector<double> upper_bound;
9     cv::Mat gray_img;
10    std::vector<std::vector<double>> population;
11    std::vector<double> fitness_values;
12    FitnessMetric metric;
13
14    void initialize_population();
15    void evaluate_fitness();
16    void crossover();
17    void mutate();
18 public:
19    GeneticAlgorithmReal(int pop_size, int num_genes, int num_generations,
20                        double crossover_prob, double mutation_prob,
21                        std::vector<double> lower_bound,
22                        std::vector<double> upper_bound,
23                        const cv::Mat& gray_img,
24                        FitnessMetric metric);
25
26    void operator()();
27    std::pair<std::vector<double>, double> getBestSolution();
28 };
```

Listing 6.1: Definición de la clase en `genetic_algo_img.h`

La enumeración `FitnessMetric` permite alternar entre entropía y desviación estándar como criterios de aptitud. Los miembros privados incluyen parámetros del GA (tamaño de población, generaciones, límites) y datos como la imagen de entrada y la población de individuos.

### 6.2.2. Inicialización de la Población

El método `initialize_population()` genera una población inicial de individuos aleatorios dentro de los límites establecidos:

```
1 void GeneticAlgorithmReal::initialize_population() {
2     for (auto& individual : population) {
3         for (int i = 0; i < num_genes; ++i) {
4             individual[i] = lower_bound[i] + dis(gen) * (upper_bound[i] -
5                 lower_bound[i]);
6             individual[i] = std::max(lower_bound[i],
7                 std::min(upper_bound[i], individual[i]));
8         }
9     }
10 }
```

Listing 6.2: Inicialización de la población

La función `dis(gen)` genera valores aleatorios uniformes, y las funciones `std::max` y `std::min` aseguran que  $\alpha$  y  $\delta$  permanezcan dentro de  $[0, 20]$  y  $[0, 1]$ , respectivamente.

### 6.2.3. Evaluación de la Aptitud

El método `evaluate_fitness()` calcula la aptitud de cada individuo aplicando la transformación sigmoidal:

```
1 void GeneticAlgorithmReal::evaluate_fitness() {
2     for (int i = 0; i < population_size; ++i) {
3         double alpha = population[i][0];
4         double delta = population[i][1];
5         cv::Mat transformed = sigmoid_transform(gray_img, alpha, delta);
6         cv::normalize(transformed, transformed, 0, 1, cv::NORM_MINMAX);
7         transformed.convertTo(transformed, CV_8U, 255.0);
8         if (metric == FitnessMetric::ENTROPY) {
9             double entropy_value = entropy(transformed);
10            fitness_values[i] = -entropy_value; // Minimize negative
11            entropy (maximize entropy)
12        } else { // STDDEV
13            double stddev_value = standard_deviation(transformed);
14            fitness_values[i] = -stddev_value; // Minimize negative
15            stddev (maximize stddev)
16        }
17    }
18 }
```

Listing 6.3: Evaluación de la aptitud

La imagen transformada se normaliza y convierte a formato de 8 bits. La aptitud se define como el negativo de la métrica seleccionada, permitiendo al GA maximizarla mediante un proceso de minimización.

## 6.3 Operadores Genéticos

El GA utiliza dos operadores clave: el cruce SBX y la mutación polinomial, implementados en `sbx.cpp` y `polynomial_mut.cpp`, respectivamente.

### 6.3.1. Cruce SBX

El operador Simulated Binary Crossover (SBX) genera dos descendientes a partir de dos padres, simulando un cruce binario en variables reales:

```
1 std::pair<std::vector<double>, std::vector<double>>
2 sbx(std::vector<double> f1, std::vector<double> f2, double r,
3     const std::vector<double>& lower_bound, const std::vector<double>&
4     upper_bound, double nc) {
5     std::vector<double> s1(f1.size());
6     std::vector<double> s2(f2.size());
7     for(size_t i = 0; i < f1.size(); i++) {
8         if (std::abs(f1[i] - f2[i]) < 1e-14) {
9             s1[i] = f1[i];
10            s2[i] = f2[i];
11            continue;
12        }
13        double beta = 1 + (2.0 * std::min(f1[i] - lower_bound[i],
14            upper_bound[i] - f2[i]) /
15            std::abs(f1[i] - f2[i]));
16        double alpha = 2 - std::pow(std::abs(beta), -(nc + 1.0));
17        double u = r;
18        double beta_c = (u <= 1.0 / alpha) ?
19            std::pow((u * alpha), (1.0 / (nc + 1))) :
```

```
17         std::pow((1.0 / (2.0 - u * alpha)), (1.0 / (nc +  
18             1)));  
19         s1[i] = 0.5 * (f1[i] + f2[i] - beta_c * std::abs(f2[i] - f1[i]));  
20         s2[i] = 0.5 * (f1[i] + f2[i] + beta_c * std::abs(f2[i] - f1[i]));  
21     }  
22     return {s1, s2};  
}
```

Listing 6.4: Cruce SBX

El parámetro  $\beta_c$  controla la dispersión de los descendientes ( $s1, s2$ ) respecto a los padres ( $f1, f2$ ), basado en una distribución simulada binaria ajustada por el índice  $nc$ .

### 6.3.2. Mutación Polinomial

La mutación polinomial introduce variaciones controladas en los parámetros:

```
1 std::vector<double> polynomial_mutation(std::vector<double>& x, double r,  
2 int nm) {  
3     std::vector<double> mutated_x(x.size());  
4     for (int i = 0; i < x.size(); i++) {  
5         double upper_bound = x[i] > 0 ? std::floor(x[i]) :  
6             std::ceil(x[i]);  
7         double lower_bound = x[i] < 0 ? std::floor(x[i]) :  
8             std::ceil(x[i]);  
9         double delta = std::min(upper_bound - x[i], x[i] - lower_bound) /  
10             (upper_bound - lower_bound);  
11         double deltaq = 0.0;  
12         if (r <= 0.5) {  
13             deltaq = x[i] + std::pow(2 * delta + (1 - 2 * delta) * (1 -  
14                 r), nm + 1);  
15         } else {  
16             deltaq = x[i] - std::pow(2 * (1 - delta) + 2 * (delta - 0.5)  
17                 * (1 - r), nm + 1);  
18         }  
19         mutated_x[i] = deltaq * (upper_bound - lower_bound);  
20     }  
21     return mutated_x;  
22 }
```

Listing 6.5: Mutación polinomial

El valor  $\delta_q$  representa la perturbación, cuya magnitud depende del índice de mutación  $nm$ , permitiendo ajustes finos en los parámetros.

## 6.4 Ejecución del Algoritmo

El método `operator()()` ejecuta el ciclo principal del GA:

```
1 void GeneticAlgorithmReal::operator()() {  
2     for (int generation = 0; generation < num_generations; ++generation) {  
3         std::cout << "Generation " << generation + 1 << std::endl;  
4         output_file << "Generation: " << generation + 1 << " | ";  
5         evaluate_fitness();  
6         select_best_individual();  
7         crossover();  
8         mutate();  
9         evaluate_fitness();  
10        apply_elitism();  
11    }  
}
```

```
12 }
```

Listing 6.6: Ciclo principal del algoritmo

Este ciclo itera sobre las generaciones, evaluando la aptitud, seleccionando individuos, aplicando los operadores SBX y mutación polinomial, y usando elitismo a fines de preservar la mejor solución.

## 6.5 Utilidades de Procesamiento de Imágenes

Las utilidades definidas en `image_utils.h` proporcionan las funciones necesarias para transformar y evaluar las imágenes dentro del algoritmo genético. Estas herramientas son esenciales para aplicar la transformación sigmoidal y calcular las métricas de aptitud utilizadas en el proceso de optimización.

### 6.5.1. Transformación Sigmoidal

La función `sigmoid_transform` implementa la transformación sigmoidal descrita en la ecuación (6.1), ajustando las intensidades de los píxeles de la imagen en función de los parámetros  $\alpha$  y  $\delta$ :

```
1 cv::Mat sigmoid_transform(const cv::Mat &gray_img, float alpha, float
  delta) {
2     cv::Mat new_image = gray_img.clone();
3     for (int i = 0; i < gray_img.rows; i++) {
4         for (int j = 0; j < gray_img.cols; j++) {
5             new_image.at<float>(i, j) = 1.0f / (1.0f + std::exp(-alpha *
              (gray_img.at<float>(i, j) - delta)));
6         }
7     }
8     return new_image;
9 }
```

Listing 6.7: Transformación sigmoidal

Esta función crea una copia de la imagen original y aplica la transformación a cada píxel, generando una nueva imagen con intensidades ajustadas según la fórmula sigmoidal.

### 6.5.2. Cálculo de Entropía

La función `entropy` calcula la entropía de Shannon, una métrica que mide la cantidad de información presente en la distribución de intensidades de la imagen:

```
1 double entropy(const cv::Mat& img) {
2     cv::Mat hist;
3     int histSize = 256;
4     float range[] = {0, 256};
5     const float* histRange = {range};
6     cv::calcHist(&img, 1, 0, cv::Mat(), hist, 1, &histSize, &histRange);
7     hist /= img.total();
8     double entropy = 0;
9     for (int i = 0; i < histSize; i++) {
10         float p = hist.at<float>(i);
11         if (p > 0) {
12             entropy -= p * log2(p);
13         }
14     }
15     return entropy;
16 }
```

---

Listing 6.8: Cálculo de entropía

El cálculo se basa en un histograma de 256 niveles de intensidad, normalizado por el número total de píxeles, y aplica la fórmula  $H = -\sum_{i=0}^{255} p_i \log_2(p_i)$ , donde  $p_i$  es la probabilidad de cada nivel de intensidad.

### 6.5.3. Cálculo de Desviación Estándar

La función `standard_deviation` determina la desviación estándar de las intensidades de la imagen, evaluando la dispersión del contraste:

```
1 double standard_deviation(const cv::Mat& img) {  
2     cv::Scalar mean, stddev;  
3     cv::meanStdDev(img, mean, stddev);  
4     return stddev[0];  
5 }
```

Listing 6.9: Cálculo de desviación estándar

Esta función utiliza la rutina `cv::meanStdDev` de OpenCV para obtener la media y la desviación estándar de la imagen, retornando únicamente el valor de la desviación estándar como medida de variabilidad.

## Capítulo 7

# Conclusiones

El proyecto demuestra la efectividad de los algoritmos genéticos en la optimización de funciones complejas. La implementación de técnicas avanzadas, como el cruzamiento SBX y la mutación polinomial, combinada con una estrategia de selección por torneo, ha permitido explorar de manera eficiente el espacio de soluciones y mejorar progresivamente el fitness de la población. Las herramientas de visualización y el almacenamiento de resultados facilitan el análisis del comportamiento del algoritmo y ofrecen una base sólida para futuras mejoras o aplicaciones a problemas más complejos.

Además, el algoritmo genético desarrollado constituye un marco sólido y escalable para la optimización de funciones complejas. Los resultados obtenidos respaldan la viabilidad del enfoque y abren la puerta a futuras investigaciones, ya sea para afinar los parámetros del algoritmo o para extender su aplicación a problemas con mayores dimensiones o características más complejas. Esta base permite, además, la incorporación de mejoras y la adaptación del método a diferentes contextos, consolidando su utilidad en el ámbito de la optimización computacional.

# Bibliografía

- [1] United-Imaging, “What does contrast enhancement in ct mean?,” 2024.
- [2] “Contrast enhancement techniques for medical images,” *MDPI*, 2024.
- [3] UAB News, “What you should know about medical contrast imaging,” 2024.
- [4] Level Up Coding, “Contrast enhancement techniques for medical images,” 2024.
- [5] “Contrast enhancement of medical images using a new version of the world cup optimization algorithm,” *PMC*, 2024.
- [6] “The importance of contrast enhancement in medical images analysis and diagnosis,” *International Journal of Engineering Research & Technology*, 2024.
- [7] CiteSeerX, “Contrast enhancement in medical images,” 2024.
- [8] “Contrast enhancement of medical images using a new version of the world cup optimization algorithm,” *Quantitative Imaging in Medicine and Surgery*, 2024.
- [9] “Quantifying the impact: Evaluating image contrast enhancement methods in modern applications,” *IJFMR*, 2024.
- [10] Saiwa, “What is image contrast enhancement?,” 2024.
- [11] “Adaptive quartile sigmoid function operator for color image contrast enhancement,” in *IS&T Library*, 2024.
- [12] Chegg, “An application of sigmoid functions is contrast enhancement in image processing,” 2024.
- [13] “Adaptive sigmoid function bihistogram equalization for image contrast enhancement,” *ADS*, 2024.
- [14] MachineLearningMastery.com, “A gentle introduction to sigmoid function,” 2024.
- [15] “A new approach for contrast enhancement,” *The International Arab Journal of Information Technology*, 2024.
- [16] “A new approach for contrast enhancement using sigmoid function,” *Semantic Scholar*, 2024.
- [17] GeeksforGeeks, “Sigmoid function,” 2024.
- [18] Wikipedia, “Sigmoid function,” 2024.
- [19] BotPenguin, “Sigmoid function: Types and applications,” 2024.
- [20] Britannica, “Sigmoid function — formula, derivative, & machine learning,” 2024.
- [21] Engati, “Sigmoid function,” 2024.
- [22] Analytics Vidhya, “Understand sigmoid function in artificial neural networks,” 2024.
- [23] LearnDataSci, “Sigmoid function,” 2024.
- [24] DeepAI, “Sigmoid function definition,” 2024.
- [25] MathWorks, “What is the genetic algorithm?,” 2024.
- [26] “Metaheuristics in optimization: Algorithmic perspective,” *INFORMS.org*, 2024.
- [27] DataCamp, “Genetic algorithm: Complete guide with python implementation,” 2024.

- [28] “A genetic algorithm analysis towards optimization solutions,” *ResearchGate*, 2024.
- [29] AnalytixLabs, “A complete guide to genetic algorithm — advantages, limitations & more,” 2024.
- [30] Autodesk Help, “Components of genetic algorithms,” 2024.
- [31] GeeksforGeeks, “Genetic algorithms,” 2024.
- [32] “Introduction to metaheuristic algorithms.” YouTube, 2024.
- [33] “Metaheuristic algorithms for optimization: A brief review,” *MDPI*, 2024.
- [34] Whitman College, “An introduction to genetic algorithms,” 2024.
- [35] Tishk International University, “Genetic algorithm,” 2024.
- [36] BotPenguin, “Genetic algorithms in machine learning: Understanding the basics,” 2024.
- [37] R. C. Gonzalez and R. E. Woods, *Digital Image Processing*. Pearson, 4 ed., 2018.



## Apéndice A

# GitHub

Se anexa un enlace al repositorio donde se encuentran los codigos y una README que expande la información aquí mostrada: *Click aqui para abrir el enlace al repositorio*